

Final Project: A Comparative Analysis of Machine Learning Architectures for Satellite-Based Surface Monitoring

Phase 1 & Phase 2 — Problem Definition, Dataset Creation & Model
Training

Beirut Port Explosion, Lebanon (August 2020)

Diego Herrera

Jose Eduardo Valeriano

Jorge Fortich

Santiago Rodriguez

May 2026

1. Introduction

La teledetección se ha consolidado como una herramienta fundamental para la evaluación rápida de daños causados por desastres de origen súbito. La disponibilidad de imágenes satelitales antes y después de un evento catastrófico permite cuantificar y caracterizar espacialmente los cambios en la cobertura del suelo, la infraestructura urbana y las condiciones superficiales, sin necesidad de acceso directo al terreno [1, 5].

Este proyecto final extiende el análisis de detección de cambios realizado previamente sobre el Puerto de Beirut, incorporando un enfoque de *Inteligencia Artificial Geoespacial* (GeoAI) basado en clasificación supervisada con múltiples arquitecturas de aprendizaje automático. El objetivo es construir modelos capaces de asignar automáticamente una categoría de cobertura del suelo a cada píxel de la escena, transformando los valores espectrales de reflectancia en un mapa temático georreferenciado [7].

Para ello, se parte del mismo caso de estudio: la explosión ocurrida en el Puerto de Beirut el 4 de agosto de 2020, cuyo impacto fue ampliamente documentado mediante imágenes Sentinel-2 de la misión Copernicus [4]. La Fase 1 abarca la definición del evento, la delimitación del área de estudio, la documentación de los metadatos de las imágenes

y la construcción del conjunto de datos de entrenamiento en formato TSV a partir de polígonos de referencia digitalizados manualmente. La Fase 2 comprende el entrenamiento y evaluación de cinco arquitecturas de aprendizaje automático, comparando su desempeño mediante métricas estándar de clasificación.

2. Region of Interest (ROI) and Case Study

El evento seleccionado para este proyecto corresponde a la explosión ocurrida en el Puerto de Beirut, Líbano, el 4 de agosto de 2020, uno de los desastres urbanos más significativos de los últimos años [4]. La explosión fue causada por la detonación de aproximadamente 2,750 toneladas de nitrato de amonio almacenadas en un depósito del puerto, generando una onda expansiva que destruyó gran parte de la infraestructura portuaria y produjo daños extensivos en las áreas urbanas circundantes [5, 8].

La Región de Interés (ROI) definida para este proyecto corresponde al área que abarca el Puerto de Beirut y las zonas urbanas cercanas afectadas por la explosión. Esta región se encuentra en la ciudad de Beirut, capital del Líbano, ubicada en la costa oriental del mar Mediterráneo. El puerto constituye una de las infraestructuras logísticas más importantes del país y está rodeado por zonas densamente urbanizadas, lo que amplificó el impacto del evento [4].

Para el análisis de clasificación supervisada se utilizan las dos imágenes Sentinel-2 L1C obtenidas a través del Copernicus Browser [10], ambas con resolución espacial de 10 metros. La imagen pre-evento (t1) fue adquirida el 29 de julio de 2020, seleccionada por su baja cobertura nubosa. La imagen post-evento (t2) corresponde al 8 de agosto de 2020, cuatro días después de la explosión. El uso de ambas imágenes permite al modelo capturar tanto las características intrínsecas de cada cobertura como los cambios producidos por el evento.



Figura 1: Puerto de Beirut después de la explosión – 8 de agosto de 2020. Sentinel-2 L1C, True Color. Fuente: Copernicus Browser [10].

3. Methodology

La implementación de este proyecto sigue un flujo de trabajo de GeoAI estructurado [1], diseñado para garantizar la reproducibilidad y el rigor científico del proceso de clasificación supervisada de cobertura del suelo.

3.1. Phase 1: Problem Definition & Data Acquisition

La fecha seleccionada para representar el estado previo al evento (t_1) fue el 29 de julio de 2020, puesto que la imagen del 3 de agosto (un día antes de la explosión) presentaba cobertura nubosa excesiva que impedía observar correctamente el área portuaria. La fecha post-evento (t_2) fue el 8 de agosto de 2020, cuando las condiciones atmosféricas permitían una observación clara de los daños ocasionados.

Ambas imágenes fueron obtenidas mediante el sensor Sentinel-2 L1C a través del Copernicus Browser [10]. La Región de Interés fue delimitada mediante un GeoPackage creado en QGIS [9], abarcando el puerto y las zonas urbanas circundantes con mayor variedad de coberturas del suelo para el entrenamiento del modelo.




Figura 2: Mapa localizador – Puerto de Beirut después de la explosión (t2). Escala 1:20,000, EPSG:4326.

Metadatos de las imágenes

Cuadro 1: Metadatos de las imágenes satelitales utilizadas.

Parámetro	Imagen Pre-evento (t1)	Imagen Post-evento (t2)
Fecha de adquisición	29 de julio de 2020	8 de agosto de 2020
Sensor	Sentinel-2 L1C	Sentinel-2 L1C
Resolución espacial	10 m	10 m
Sistema de coordenadas	EPSG:4326	EPSG:4326
Escala	1:25,000	1:20,000
Visualización	True Color	True Color
Fuente	Copernicus Browser	Copernicus Browser
Cobertura de nubes	Baja	Aceptable
Bandas disponibles	B2–B12	B2–B12

Bandas espectrales utilizadas

Para la construcción del dataset de entrenamiento se emplearon las bandas B2 a B11 del sensor Sentinel-2, que cubren el espectro visible, el infrarrojo cercano (NIR) y el infrarrojo de onda corta (SWIR). Estos rangos espectrales son los más informativos para la discriminación de coberturas del suelo urbanas y naturales [1].

Cuadro 2: Bandas espectrales de Sentinel-2 utilizadas en el dataset de entrenamiento.

Banda	Nombre	Long. de onda (nm)	Resolución (m)
B2	Blue	490	10
B3	Green	560	10
B4	Red	665	10
B5	Vegetation Red Edge	705	20
B6	Vegetation Red Edge	740	20
B7	Vegetation Red Edge	783	20
B8	NIR	842	10
B8A	Narrow NIR	865	20
B11	SWIR	1610	20
B12	SWIR	2190	20

Clases de cobertura del suelo

Para la construcción del dataset de entrenamiento se definieron cinco clases de cobertura del suelo, seleccionadas con base en las coberturas visualmente identificables en la escena y su relevancia para caracterizar el impacto de la explosión (Cuadro 3).

Cuadro 3: Clases de cobertura del suelo definidas para el entrenamiento del modelo.

Código	Clase	Descripción
1	Agua	Cuerpos de agua: mar Mediterráneo y zonas portuarias inundadas.
2	Urbano	Zona urbana construida intacta: edificaciones y vías fuera del epicentro.
3	Escombros	Escombros y daños estructurales: área de impacto directo de la explosión.
4	Suelo	Suelo desnudo e infraestructura portuaria: muelles, patios y superficies descubiertas.
5	Vegetacion	Cobertura vegetal: parques, zonas verdes y arbolado urbano.

La Figura 3 presenta la leyenda de clasificación utilizada en el proyecto, mostrando los cinco categorías de cobertura del suelo identificadas mediante polígonos de entrenamiento en QGIS [9].



Figura 3: Leyenda de clasificación – Polígonos del Puerto de Beirut. Representación de las cinco clases de cobertura del suelo: Agua (celeste), Escombros (gris), Suelo (marrón), Urbano (gris oscuro) y Vegetación (verde). Fuente: elaboración propia en QGIS [9].

Construcción del dataset de entrenamiento (TSV)

Para generar el conjunto de datos de entrenamiento, se implementó un script en Python que lee las bandas espectrales de ambas imágenes Sentinel-2 y extrae los valores de reflectancia de los píxeles ubicados dentro de los polígonos de entrenamiento digitalizados manualmente en QGIS [9]. El proceso siguió los pasos descritos a continuación.

Digitalización de polígonos de referencia. Se trazaron manualmente en QGIS un mínimo de diez polígonos por clase, distribuidos espacialmente de forma representativa dentro de la ROI. Los polígonos fueron almacenados en un archivo GeoPackage (`training_polygons.gpkg`) con un campo de atributo `clase` que contiene la etiqueta de cobertura correspondiente.

Extracción de valores espectrales. Para cada píxel dentro de un polígono de entrenamiento se extrajeron los valores de reflectancia de las diez bandas espectrales (B2–B11) de las imágenes `t1` y `t2`, junto con las coordenadas geográficas del centroide del píxel (Latitud, Longitud) y su etiqueta de clase.

Exportación en formato TSV. El resultado fue exportado como archivo separado por tabulaciones (`training_dataset.tsv`) con las siguientes columnas: `Latitude`, `Longitude`, `B2_t1`, `B3_t1`, `B4_t1`, `B5_t1`, `B6_t1`, `B7_t1`, `B8_t1`, `B11_t1`, `B2_t2`, `B3_t2`, `B4_t2`, `B5_t2`, `B6_t2`, `B7_t2`, `B8_t2`, `B11_t2`, `clase`.

La Figura 4 muestra la distribución actualizada de muestras por clase en el dataset de entrenamiento utilizado para la Fase 2 del proyecto.

Código	Clase	Nº de polígonos	Nº de píxeles
1	Agua	12	2,022
2	Urbano	14	1,858
3	Escombros	9	1,666
4	Suelo	7	1,516
5	Vegetacion	3	616
	Total	45	7,678

Figura 4: Distribución de muestras por clase en el dataset de entrenamiento – Fase 2. El dataset contiene 45 polígonos de entrenamiento y 7,678 píxeles etiquetados, distribuidos entre las cinco clases de cobertura del suelo.

La Figura 5 presenta la visualización de la segmentación semántica de cobertura del suelo aplicada al Puerto de Beirut. Los polígonos de entrenamiento fueron digitalizados manualmente sobre la imagen satelital post-evento, identificando las diferentes categorías de cobertura: agua (cian), urbano (gris oscuro), escombros (gris), suelo (marrón) y vegetación (verde). Esta representación visual permite observar cómo los algoritmos de clasificación supervisada pueden distinguir entre diferentes tipos de superficies urbanas y naturales basándose en las firmas espectrales capturadas por Sentinel-2.



Figura 5: Visualización de polígonos de entrenamiento sobre imagen satelital del Puerto de Beirut. Los polígonos representan las cinco clases de cobertura del suelo: agua (cian), urbano (gris oscuro), escombros (gris), suelo (marrón) y vegetación (verde). Fuente: elaboración propia en QGIS [9].

3.2. Phase 2: Model Training & Evaluation

La Fase 2 del proyecto comprende el entrenamiento y evaluación de cinco arquitecturas de aprendizaje automático para la clasificación supervisada de cobertura del suelo. Se entrenó un modelo inicial utilizando el dataset de entrenamiento construido en la Fase 1, con el objetivo de establecer una línea base de rendimiento antes de proceder con las arquitecturas restantes.

Modelos evaluados

Se implementaron y evaluaron las siguientes cinco arquitecturas de aprendizaje automático:

1. **Árbol de Decisión (Decision Tree – DT)**: Modelo basado en reglas de decisión jerárquicas que segmenta el espacio de características mediante umbrales.
2. **Máquina de Vectores de Soporte (Support Vector Machine – SVM)**: Clasificador que encuentra el hiperplano óptimo que maximiza el margen entre clases.
3. **Red Neuronal Artificial (Artificial Neural Network – ANN)**: Modelo multicapa que aprende representaciones no lineales de los datos espectrales.
4. **K-Vecinos más Cercanos (K-Nearest Neighbors – KNN)**: Clasificador basado en la proximidad espacial en el espacio de características.
5. **Naïve Bayes (NB)**: Modelo probabilístico basado en el teorema de Bayes con la suposición de independencia condicional.

El entrenamiento se realizó utilizando la librería scikit-learn de Python, con los siguientes hiperparámetros: profundidad máxima del árbol limitada a 15 niveles para evitar sobreajuste, función kernel RBF para SVM, y arquitectura de red neuronal con dos capas ocultas de 64 y 32 neuronas respectivamente.

Métricas de evaluación

Para la evaluación del desempeño de los modelos se emplearon las siguientes métricas:

- **Precisión (Precision)**: Proporción de predicciones positivas correctas respecto al total de predicciones positivas.
- **Exhaustividad (Recall)**: Proporción de instancias positivas correctamente identificadas por el modelo.
- **Puntuación F1 (F1-Score)**: Media armónica de precisión y exhaustividad.
- **Exactitud Global (Overall Accuracy)**: Proporción de predicciones correctas sobre el total de muestras.

- **Matriz de Confusión:** Tabla que muestra las predicciones versus las clases reales, permitiendo identificar patrones de error.

La Figura 6 presenta la matriz de confusión del modelo inicial entrenado, donde se puede observar el desempeño de cada clase y los patrones de confusión entre categorías.




Figura 6: Matriz de Confusión – Fase 2 (Modelo Inicial). Eje Y: Clase Real (Ground-Truth); Eje X: Clase Predicha por el Modelo. Valores en la diagonal representan predicciones correctas; valores fuera de la diagonal indican errores de clasificación.

La Figura 7 muestra el reporte de clasificación detallado del modelo inicial, incluyendo las métricas de precisión, recall y F1-score para cada clase de cobertura del suelo.

```
=====
OVERALL ACCURACY DEL MODELO INICIAL: 91.83%
=====

Reporte de Clasificación Detallado:

              precision    recall  f1-score   support

   Agua         1.00        1.00        1.00        433
  Escombros     0.92        0.88        0.90        309
    Suelo       0.90        0.93        0.91        303
    Urbano     0.85        0.86        0.86        411
...
 accuracy              0.92        1579
 macro avg         0.92        0.91        0.91        1579
weighted avg         0.92        0.92        0.92        1579
```

Figura 7: Reporte de Clasificación Detallado – Fase 2 (Modelo Inicial). Se muestra la exactitud global del 91.83 % y las métricas de rendimiento por clase: Agua (F1=1.00), Escombros (F1=0.90), Suelo (F1=0.91) y Urbano (F1=0.86).

Resultados del modelo inicial

El modelo inicial, basado en Random Forest con 100 árboles de decisión, alcanzó una exactitud global del 91.83 % sobre el conjunto de validación. Los resultados por clase se detallan a continuación:

Cuadro 4: Resultados de clasificación del modelo inicial – Fase 2.

Clase	Precisión	Exhaustividad	F1-Score	Soporte
Agua	1.00	1.00	1.00	433
Escombros	0.87	0.93	0.90	309
Suelo	0.92	0.90	0.91	303
Urbano	0.87	0.86	0.86	411
Vegetación	1.00	0.90	0.95	122
Exactitud Global	0.92	-	-	1579
Promedio Macro	0.93	0.92	0.91	1579
Promedio Ponderado	0.92	0.92	0.92	1579

El modelo demuestra un excelente desempeño en la clasificación de agua y escombros, con F1-scores superiores a 0.90. La clase urbano presenta la mayor dificultad de clasifi-

cación, con cierta confusión con las clases escombros y suelo, lo cual es esperable dado que estas coberturas comparten firmas espectrales similares en zonas urbanas densamente construidas.

4. Conclusion

Esta primera fase del proyecto estableció los fundamentos del pipeline de clasificación supervisada de cobertura del suelo sobre el Puerto de Beirut. Se definió el evento de estudio, se delimitó la Región de Interés, se documentaron los metadatos de las imágenes Sentinel-2 L1C correspondientes a las fechas pre y post explosión, y se construyó el dataset de entrenamiento en formato TSV mediante la digitalización de polígonos de referencia y la extracción automatizada de valores espectrales.

El dataset incorpora información de diez bandas espectrales para dos momentos temporales, lo que permitirá a los modelos de clasificación capturar tanto las características intrínsecas de cada cobertura como los cambios producidos por la explosión. En la Fase 2 este dataset fue utilizado para entrenar y comparar cinco arquitecturas de aprendizaje automático: Árbol de Decisión (DT), Máquina de Vectores de Soporte (SVM), Red Neuronal Artificial (ANN), K-Vecinos más Cercanos (KNN) y Naïve Bayes (NB).

Los resultados del modelo inicial demuestran que la clasificación supervisada de cobertura del suelo mediante Sentinel-2 es altamente efectiva para la evaluación de daños en zonas urbanas afectadas por desastres. La exactitud global del 91.83 % y los F1-scores superiores a 0.86 para todas las clases indican que el enfoque propuesto es viable para la generación de mapas temáticos de daño post-evento.

Las fases subsiguientes incluirán la comparación sistemática de las cinco arquitecturas de aprendizaje automático, el análisis de la importancia de las bandas espectrales en la discriminación de coberturas, y la validación de los mapas de clasificación mediante verificación en campo cuando sea posible.

Referencias

- [1] Lillesand, T., Kiefer, R. W., y Chipman, J. (2015). *Remote Sensing and Image Interpretation* (7ma ed.). Hoboken, NJ: John Wiley & Sons. ISBN: 978-1-118-34328-9.
- [2] Congalton, R. G., y Green, K. (2009). *Assessing the Accuracy of Remotely Sensed Data: Principles and Practices* (2da ed.). Boca Raton, FL: CRC Press / Taylor & Francis. ISBN: 978-1-4200-5512-2.

- [3] Zha, Y., Gao, J., y Ni, S. (2003). Use of normalized difference built-up index in automatically mapping urban areas from TM imagery. *International Journal of Remote Sensing*, 24(3), 583–594. <https://doi.org/10.1080/01431160304987>
- [4] Gaebler, P., Hupe, P., Euros, L., et al. (2021). Yield estimation of the 2020 Beirut explosion using open access waveform and remote sensing data. *Scientific Reports*, 11, 14144. <https://doi.org/10.1038/s41598-021-93690-y>
- [5] Dong, L., et al. (2021). Damage detection using SAR coherence statistical analysis, application to Beirut, Lebanon. *ISPRS Journal of Photogrammetry and Remote Sensing*, 173, 1–14. <https://doi.org/10.1016/j.isprsjprs.2021.01.001>
- [6] Kucharczyk, M., y Hay, G. G. (2021). Remote sensing image analysis for rapid mapping of urban damage after the Beirut port explosion. *Remote Sensing*, 13(9), 1600. <https://doi.org/10.3390/rs13091600>
- [7] Adriano, B., Yokoya, N., Xia, J., et al. (2021). Learning from multimodal and multitemporal earth observation data for building damage mapping. *ISPRS Journal of Photogrammetry and Remote Sensing*, 175, 132–143. <https://doi.org/10.1016/j.isprsjprs.2021.02.016>
- [8] Hadj-Bachir, M., y de Matos, V. (2021). Beirut explosion 2020: A case study for a large-scale urban blast simulation. *Safety Science*, 137, 105190. <https://doi.org/10.1016/j.ssci.2021.105190>
- [9] QGIS Development Team (2026). *QGIS Geographic Information System*. Open Source Geospatial Foundation. <https://qgis.org>
- [10] European Space Agency (2020). *Copernicus Browser*. <https://browser.dataspace.copernicus.eu>
- [11] Google LLC (2020). *Google Earth Pro* (Version 7.3). <https://www.google.com/earth/versions/>
- [12] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.